Accordo dimostrativo di servizi

Documento fittizio di tre pagine - creato per esercizi di estrazione del testo dai PDF con Python.

Parti e contesto

Il presente accordo dimostrativo è stipulato tra Società Esempio S.r.l., denominata di seguito «Committente», e Laboratorio Dimostrativo, denominato «Fornitore». Tutti i nomi, gli importi e le condizioni di questo documento sono inventati e non costituiscono un accordo utilizzabile.

Articolo 1 - Oggetto

Il Fornitore realizzerà un servizio sperimentale di organizzazione e consultazione di documenti digitali. Le attività previste comprendono acquisizione di file PDF, estrazione di testo selezionabile, registrazione dei metadati principali e predisposizione di una funzione di ricerca per categoria.

L’obiettivo del progetto dimostrativo è verificare che i documenti possano essere trasformati in informazioni strutturate, conservando il riferimento alla pagina di origine. Il risultato dovrà essere leggibile sia da programmi Python sia da un’interfaccia di consultazione.

Articolo 2 - Durata

Il periodo di attività indicativo è di trenta giorni dalla data di avvio. Entro i primi dieci giorni il Fornitore prepara il flusso di lettura dei PDF; entro i successivi dieci giorni organizza i metadati; nel periodo finale verifica i risultati su documenti di prova.

Articolo 3 - Documentazione

Per ogni file elaborato devono essere registrati almeno il nome del documento, il numero delle pagine e il testo estratto. Il titolo può essere ricavato inizialmente dal nome del file; l’eventuale classificazione nella categoria «Legale», «Finanza» o «Tecnico» sarà fornita separatamente.

Attività previste e criteri di verifica

Seconda pagina - una tabella e diversi paragrafi per esercitare l’estrazione del testo.

Articolo 4 - Fasi operative

Il lavoro è suddiviso in tre fasi. Ciascuna fase produce un risultato verificabile e potrà essere esaminata indipendentemente dalle altre.

Fase	Attività	Risultato previsto
1	Lettura del PDF	Testo estratto e numero di pagine
2	Strutturazione	Metadati organizzati per documento
3	Verifica	Controlli di qualità e resoconto

Articolo 5 - Qualità dei dati

L’estrazione del testo deve mantenere, ove possibile, la punteggiatura e i caratteri accentati. Per esempio, i termini «informazione», «qualità», «perché» e «attività» dovrebbero essere recuperati come normali stringhe Unicode. La presenza di tabelle può tuttavia influenzare l’ordine con cui i contenuti vengono estratti.

Quando una pagina contiene soltanto un’immagine acquisita con scanner, la semplice estrazione testuale potrebbe restituire una stringa vuota. In tale situazione è necessario valutare un processo separato di riconoscimento ottico dei caratteri (OCR).

Articolo 6 - Criteri di accettazione

Il documento è considerato elaborato correttamente quando il programma restituisce il numero totale di pagine, una stringa di testo per ciascuna pagina e un risultato complessivo consultabile. Il programma deve inoltre gestire in modo esplicito l’assenza del file e gli eventuali errori di apertura.

Riepilogo e dati di esempio

Terza pagina - contenuto finale utile per verificare il ciclo su tutte le pagine.

Articolo 7 - Dati economici dimostrativi

A titolo puramente illustrativo, il valore complessivo del progetto è indicato in 2.500,00 euro, ripartito tra le tre fasi operative. Nessuna cifra riportata in questo documento ha valore contrattuale o fiscale.

Articolo 8 - Riservatezza

I partecipanti all’esercitazione utilizzeranno soltanto dati fittizi. Non devono essere caricati nel sistema documenti contenenti informazioni personali o riservate senza una valutazione delle misure di sicurezza e dei permessi di accesso.

Articolo 9 - Riepilogo tecnico

Questo file è un PDF digitale, quindi il testo è selezionabile e può essere estratto direttamente con PyMuPDF. Il documento contiene esattamente tre pagine. L’esercizio consiste nell’aprire il file, contare le pagine, estrarre il testo e stampare una porzione dei caratteri recuperati.

Per la successiva fase del progetto, il testo potrà essere suddiviso in porzioni più piccole chiamate chunk. Ogni chunk potrà conservare i riferimenti al documento e alla pagina di origine, in modo da rendere più affidabile il recupero dei contenuti.

Nota finale

Il contenuto di questo documento è stato creato esclusivamente come materiale didattico per il progetto Agentic Document Intelligence. Non rappresenta un contratto reale, un modello legale approvato o un parere professionale.

Fine del documento di prova.